

Relatório de Transformações de Dados

1. Objetivo	2
2. Descrição do Dataset	3
3. Arquitetura de Dados	3
4. Problemas Identificados nos Dados	4
5. Transformações Realizadas	4
5.1 Variável: Chassi	4
5.2 Variável: Marca	5
5.4 Variável: Carroceria	5
5.5 Variável: Estado	5
5.6 Variável: Condição	6
5.7 Variável: Odômetro	6
5.8 Variáveis de Preço (MMR e Venda)	6
5.9 Variável: Data de Venda	6
5.10 Variável: Ano	7
6. Regras de Validação	7
7. Pipeline de Processamento	7
8. Impacto das Transformações	7
9. Conclusão	8

1. Objetivo

Este documento tem como objetivo descrever as transformações aplicadas ao dataset de vendas automotivas, visando garantir a qualidade, consistência e confiabilidade dos dados.

As transformações realizadas são fundamentais para assegurar que as análises reflitam a realidade do negócio e possam apoiar decisões estratégicas, como a avaliação de desempenho das marcas no portfólio da American Auto.

2. Descrição do Dataset

O dataset utilizado foi obtido a partir da plataforma Kaggle e contém informações relacionadas às vendas de veículos no mercado dos Estados Unidos.

Entre as principais variáveis analisadas estão:

- Ano do veículo
- Marca
- Modelo
- Carroceria
- Estado
- Condição do veículo
- Odômetro
- Preço de venda
- Preço MMR
- Preço Venda
- Data de venda

Os dados foram inicialmente ingeridos em seu formato bruto na camada Bronze.

3. Arquitetura de Dados

Para organizar o processamento, foi adotada uma arquitetura em três camadas:

- **Bronze:** Armazenamento dos dados brutos, sem alterações
- **Silver:** Dados tratados, com aplicação de regras de limpeza, padronização e validação
- **Gold:** Dados estruturados para consumo analítico e geração de insights

Essa abordagem garante organização, rastreabilidade e escalabilidade no fluxo de dados.

4. Problemas Identificados nos Dados

Durante a análise inicial, foram identificados diversos problemas que poderiam comprometer a qualidade das análises:

- Presença de valores nulos
- Inconsistências nos nomes de marcas e modelos
- Mistura de informações em uma mesma variável
- Formatos incorretos de dados
- Valores inválidos em variáveis numéricas

- Registros fora do escopo geográfico do projeto
- Dados fora de intervalos esperados

Esses problemas exigiram a aplicação de transformações estruturadas.

5. Transformações Realizadas

As transformações foram aplicadas principalmente na camada Silver, com foco na qualidade dos dados.

5.1 Variável: Chassi

- **Problema:** Formato inconsistente e registros inválidos
- **Ação:**
 - Validação do comprimento (17 caracteres)
 - Remoção de espaços
 - Padronização para letras maiúsculas
 - Exclusão de registros inválidos
- **Resultado:** Garantia de integridade e padronização da variável

5.2 Variável: Marca

- **Problema:** Valores nulos e inconsistências de escrita
- **Ação:**
 - Remoção de valores nulos
 - Padronização dos nomes
 - Correção de inconsistências
 - Remoção de sufixos numéricos
- **Resultado:** Uniformidade na identificação das marcas

5.3 Variável: Modelo

- **Problema:** Mistura entre modelo e carroceria e inconsistências
- **Ação:**
 - Remoção de valores nulos
 - Correção de inconsistências
 - Separação entre modelo e carroceria

- Ajustes manuais
- **Resultado:** Maior precisão na análise por modelo

5.4 Variável: Carroceria

- **Problema:** Dados inconsistentes e mistura com outras variáveis
- **Ação:**
 - Remoção de valores nulos
 - Padronização das categorias
 - Normalização via mapeamento
- **Resultado:** Consistência nas categorias de veículos

5.5 Variável: Estado

- **Problema:** Presença de registros fora do escopo (outros países)
- **Ação:**
 - Filtragem apenas para estados dos Estados Unidos
 - Padronização dos dados
 - Criação da variável “região”
- **Resultado:** Coerência geográfica para análise

5.6 Variável: Condição

- **Problema:** Dificuldade de interpretação direta
- **Ação:**
 - Cálculo de percentis
 - Criação de categorias de qualidade
- **Resultado:** Melhor interpretabilidade da variável

5.7 Variável: Odômetro

- **Problema:** Valores nulos e inválidos
- **Ação:**
 - Remoção de registros inválidos

- Filtragem de valores inconsistentes
- **Resultado:** Garantia de integridade dos dados

5.8 Variáveis de Preço (MMR e Venda)

- **Problema:** Valores nulos e inconsistentes
- **Ação:**
 - Remoção de valores nulos
 - Validação de valores positivos
- **Resultado:** Dados confiáveis para análise financeira

5.9 Variável: Data de Venda

- **Problema:** Formatos inconsistentes
- **Ação:**
 - Conversão e padronização das datas
 - Remoção de registros inválidos
 - Extração de ano e mês
- **Resultado:** Viabilização da análise temporal

5.10 Variável: Ano

- **Problema:** Valores fora do intervalo esperado
- **Ação:**
 - Validação de intervalo
- **Resultado:** Consistência temporal

6. Regras de Validação

Foram aplicadas regras específicas para garantir a qualidade dos dados:

- Chassi com 17 caracteres
- Preços maiores que zero
- Ano dentro de intervalo válido
- Estados pertencentes aos Estados Unidos
- Campos obrigatórios não nulos

7. Pipeline de Processamento

As transformações foram organizadas em um pipeline estruturado com funções reutilizáveis.

Esse pipeline permite:

- Execução padronizada do tratamento
- Facilidade de manutenção
- Reprocessamento automático de novos dados
- Escalabilidade para futuras atualizações

8. Impacto das Transformações

As transformações realizadas resultaram em:

- Melhoria significativa na qualidade dos dados
- Redução de inconsistências
- Padronização das variáveis
- Maior confiabilidade nas análises
- Base sólida para geração de insights

9. Conclusão

As transformações aplicadas foram essenciais para garantir a integridade e confiabilidade do dataset.

A estruturação do pipeline e a aplicação de regras de validação permitiram a construção de uma base de dados robusta, capaz de sustentar análises estratégicas e apoiar decisões de negócio, como a identificação de marcas com baixa performance no portfólio.